ECOX14 — ENGENHARIA DE DADOS NA PRÁTICA

Life Expectancy

Camadas bronze e prata

> Por que alguns países vivem mais que outros — quanto o nível de renda, a escolaridade e o gasto em saúde explicam da expectativa de vida?

Artur Macedo Costa · 2024012996

De onde veio o dado

OMS (World Health Organization)

Fonte oficial de saúde. Acesso por API, sem cadastro.

WHOSIS_000001 — expectativa de vida

GHED_CHEGDP_SHA2011 — gasto em saúde (% do PIB)

GHED_CHE_pc_US_SHA2011 — gasto por habitante

Banco Mundial

Dados econômicos e sociais. Acesso por API, sem cadastro.

NY.GDP.PCAP.CD — PIB per capita

SE.SCH.LIFE — escolaridade esperada

/v2/country — lista de países

> Não usei a planilha que circula no Kaggle, porque é uma cópia de 2015. A API da OMS vai até 2021 e traz os dados separados por sexo.

O dado bruto

Baixei 29.338 registros. Cada arquivo foi salvo exatamente como o servidor entregou, sem mudar nada — todos em JSON.

Fonte	O que é	Registros
OMS	expectativa de vida	11.172
OMS	gasto em saúde (% do PIB)	3.824
OMS	gasto em saúde por habitante	3.824
Banco Mundial	lista de países	296
Banco Mundial	PIB per capita	5.054
Banco Mundial	escolaridade esperada	5.168

> As duas APIs entregam os dados aos poucos, em partes. Meu script percorre todas as páginas e confere se chegou tudo. Se faltar alguma coisa, o script não salva o arquivo — assim nunca passa um pedaço incompleto sem eu perceber.

O que estava errado no dado

Rodei uma ferramenta de análise em cada arquivo. Ela aponta os problemas. Esses foram os principais:

O que foi apontado	O que acontece se eu não arrumar
Número escrito como texto (a OMS entrega '54.2 [51.2-57.2]')	o computador não consegue comparar nem somar os valores
Grupos de países misturados com países (627 das 11.172 linhas)	a "América do Sul" entraria na conta como se fosse o Brasil
Metade da escolaridade sem dado (2.214 de 5.168 registros)	a comparação entre países fica enviesada
Duas colunas totalmente vazias	ocupam espaço e não servem para nada

> O mais difícil foi separar os países dos grupos de países, porque a OMS não tem nenhuma coluna que faça isso. Achei a solução lendo a documentação da API: existe uma coluna em que a fonte diz o que cada linha é.

Como resolvi

Problema	O que fiz	Resultado
Números como texto	li o número do campo certo	10.545 valores utilizáveis
Grupos misturados com países	usei a coluna que a OMS preenche	expectativa 11.172 → 10.545 gasto 3.824 → 3.615 países 296 → 217
Colunas vazias	contei e apaguei	2 colunas a menos
Renda sem ordem	coloquei os 4 níveis em ordem	dá para comparar e somar
Ano com formato de data	guardei como número inteiro	2000 a 2018
Linhas sem nenhum dado	apaguei 107 linhas	ex.: Gibraltar

> Duas coisas eu mantive. 38 linhas sem nome de país — Ilhas Cook e Niue existem, mas o Banco Mundial não lista. E 59 valores de gasto em saúde fora do padrão: gastar muito não quer dizer que o dado está errado, então marquei em vez de apagar.

Juntei os dados das duas fontes

A OMS entrega só o código do país, como BRA, sem o nome. O Banco Mundial tem a lista com nome, região e nível de renda.

OMS

BRA · 2000
total
71,5 anos

+

Banco Mundial

BRA = Brasil
região
renda

=

Resultado

Brasil · 2000
renda média alta
71,5 anos

Nada se perdeu na junção: as duas fontes usam o mesmo código de país, então a ligação é direta. É só aqui que a renda vira categoria ordenada — nenhuma das duas fontes, sozinha, tem essa escala.

Criei 6 colunas novas

Das 31 colunas da tabela final, 25 vieram das fontes. Estas 6 não existiam:

Calculadas pelo código

variacao_pct — quanto mudou no ano

expectativa_vida_faixa — faixa (quartil)

escolaridade_anos_faixa — faixa (quartil)

Vieram da junção

pais_nome — o nome que a OMS não dá

regiao — a região do país

nivel_renda — a faixa de renda, ordenada

As três da esquerda são novas: não existem em nenhuma das fontes. As três da direita só aparecem depois que as duas fontes são juntas — a OMS entrega o código do país, e o nome, a região e a faixa de renda vêm do Banco Mundial.

Acrescentei colunas que respondem perguntas

Além das colunas que vieram das fontes, criei três que ajudam a responder a pergunta do projeto.

Coluna	O que faz
variacao_pct	mostra quanto a expectativa de vida mudou em relação ao ano anterior, separando por sexo
expectativa_vida_faixa	divide os países em 4 faixas, todas do mesmo tamanho
escolaridade_anos_faixa	o mesmo, para a escolaridade

> Para que serve a variação? O Rwanda subiu de 49 para 68 anos entre 2001 e 2018. Olhando só os valores, parece uma subida constante. Mas o quanto ganhou por ano caiu de 2,9% para 0,3%. A coluna nova mostra uma desaceleração que a coluna original esconde.

Os maiores saltos são fatos reais

Onde a expectativa de vida mudou mais de 10% em um ano, quase sempre aconteceu um evento grave — guerra, epidemia, desastre natural.

País	Ano	O que mudou	O que aconteceu
República Centro-Africana	2009	−48,0%	epidemia de HIV/AIDS e conflito armado
Haiti	2010	−34,8%	terremoto de janeiro de 2010
Somália	2011	−30,5%	fome de 2011
Haiti	2011	+54,1%	recuperação do sistema de saúde
Somália	2012	+43,9%	fim da fome
República Centro-Africana	2010	+89,0%	recuperação após o ano de crise

> São 39 casos em 8 países, e nenhum deles é erro de cálculo. Se eu tivesse apagado essas linhas como “valor estranho”, teria perdido a informação mais importante que a fonte traz sobre esses países.

A pergunta tem resposta

Expectativa de vida média (anos) e PIB per capita (US$) por nível de renda.

Nível de renda	2000	2018	Ganho	PIB 2018
Baixa	53,2	62,6	+9,4	US$ 676
Média baixa	61,0	67,9	+6,8	US$ 2.350
Média alta	69,6	73,8	+4,2	US$ 6.739
Alta	75,7	79,4	+3,8	US$ 36.906

> Quanto mais pobre o país, mais ganhou. A distância entre os extremos era de 22,5 anos e é de 16,8 — diminuiu, mas não acabou.

O PIB de 2018 multiplica por 55 entre os extremos, mas a expectativa de vida ganha só 16 anos. É a diferença entre ter recursos e transformar recursos em anos de vida.

Limitações e o que vem agora

Limitações

- A escolaridade tem menos países por ano (92 a 116) que a expectativa de vida (185) — a comparação olha um grupo menor
- O período vai até 2018 porque a escolaridade parou em 2019
- A OMS atualizou os dados em outubro e mudou o número de casas decimais

Camada ouro

- Modelar os dados para responder à pergunta
- Transformação em SQL
- Testes e documentação
- Painel com gráficos

As tabelas já estão prontas e se cruzam por país e ano: 10.545 registros de expectativa de vida e 4.016 de determinantes.