

UNIVERSIDADE FEDERAL DE ITAJUBÁ

Engenharia de Dados na Prática

Aula 1 | O que é engenharia de dados

Profa. Bárbara Pimenta Caetano

ROTEIRO

O que veremos hoje

- 01** **Uma pergunta simples**
e tudo o que precisa existir para respondê-la
- 02** **O que faz um engenheiro de dados**
definição, ciclo de vida do dado e funções vizinhas
- 03** **O mercado brasileiro de dados**
resultados do State of Data 2025-2026
- 04** **O que você vai construir aqui**
o projeto do semestre em três camadas
- 05** **Atividade de hoje**
escolha do seu tema e da sua fonte de dados

PARA COMEÇAR

Quantas pessoas usaram o transporte público da sua cidade ontem?

A pergunta é trivial. A resposta depende de uma infraestrutura inteira que quase ninguém vê.

ANTES DA ANÁLISE

O caminho até a resposta

01

Coletar

Catracas, aplicativos e bilhetagem geram registros o tempo todo

02

Armazenar

Esses registros precisam ir para algum lugar confiável

03

Limpar

Duplicidades, falhas de leitura e horários inválidos aparecem

04

Integrar

Linhas, estações e calendário vêm de sistemas diferentes

05

Entregar

Só então a pergunta vira um número em uma tela

Todo esse percurso é engenharia de dados. A análise começa onde ele termina.

DEFINIÇÃO

O que é engenharia de dados

Engenharia de dados é a disciplina que projeta, constrói e mantém os sistemas que transformam dados brutos em dados confiáveis, disponíveis e prontos para uso.

● **Confiabilidade**

O dado chega completo, no formato esperado e sem surpresas silenciosas

● **Reprodutibilidade**


O processo roda de novo amanhã e produz o mesmo resultado

● **Escala**

O que funciona com mil linhas continua funcionando com dez milhões

MAPA DO SEMESTRE

O ciclo de vida do dado




Sustentando todas as etapas



Cada semana avançaremos um trecho deste caminho.

Referência: Reis, J.; Housley, M. Fundamentals of Data Engineering. O'Reilly, 2022.

O ciclo no exemplo do transporte público




Os três primeiros estágios são engenharia de dados. A análise começa no quarto.

Engenheiro de Dados

Cientista de Dados

Analista de Dados



QUEM FAZ O QUÊ

Três funções, três perguntas

Engenheiro de dados

Como faço este dado existir, chegar limpo e continuar chegando?

Pipelines, bancos, orquestração, qualidade

Cientista de dados

O que este dado consegue prever ou explicar?

Estatística, modelos, experimentação

Analista de dados

O que este dado diz sobre o negócio agora?

Consultas, indicadores, relatórios

As três funções convivem. A diferença está na pergunta que cada uma resolve primeiro.

Nada acontece sem a base

Inteligência artificial e aprendizado de máquina

Análise, indicadores e experimentação

Dados limpos, integrados e confiáveis

Coleta, ingestão e armazenamento

As duas camadas de baixo são engenharia de dados. Elas sustentam tudo o que está acima.

QUANDO O DADO FALHA

Pipeline quebrado não avisa. Ele simplesmente entrega um número errado com toda a confiança.

Três casos documentados do que acontece quando a engenharia de dados falha.

Três falhas, três estágios do ciclo

1999

Mars Climate Orbiter

Dois sistemas trocavam dados de propulsão em unidades diferentes, sem que nenhum contrato de dados explicitasse qual era a esperada. A sonda entrou na atmosfera de Marte em altitude errada e foi perdida.

Falha de geração e integração

US\$ 125 milhões

2020

Public Health England

Resultados de teste de covid eram coletados em arquivos no formato antigo .xls, limitado a 65.536 linhas. Quando o arquivo enchia, os novos registros eram descartados em silêncio, sem erro.

Falha de ingestão

15.841 casos não reportados

2020

Auxílio Emergencial

O cadastro de beneficiários não foi confrontado adequadamente com outras bases públicas antes do pagamento, permitindo benefícios a pessoas falecidas, com renda acima do limite ou com CPF cancelado.

Falha de transformação e integração

620.299 beneficiários com indício de pagamento indevido

STATE OF DATA 2025-2026

O mercado brasileiro de dados

Pesquisa conduzida pela comunidade **Data Hackers** em parceria com a **Bain & Company**, no quinto ano consecutivo. Retrata o perfil e a remuneração dos profissionais de dados no Brasil.

3.200 respondentes brasileiros

5 anos de série histórica

out a dez de 2025, período de coleta

Por que isso importa?


- É a referência mais usada no país para discutir carreira em dados.
- Permite comparar funções, senioridade e faixas de remuneração.
- Mostra para onde o mercado está se movendo nos próximos anos.

Fonte: Data Hackers e Bain & Company. State of Data Brasil 2025-2026.

REMUNERAÇÃO POR FUNÇÃO

Quem alcança as faixas mais altas

Proporção de profissionais que recebem acima de R\$ 12 mil por mês



43,5%

dos engenheiros de dados recebem acima de R\$ 12 mil por mês, a maior proporção entre as funções da área.

Fonte: Data Hackers e Bain & Company. State of Data Brasil 2025-2026.

INDICADORES DE 2025

Um mercado ainda aquecido

6,7%

de aumento médio na remuneração dos profissionais de dados em 2025

Acima da inflação oficial do período, de 4,26%

51,3%

participaram de entrevistas de emprego nos seis meses anteriores

Sinal de alta procura por esses profissionais

83,4%

apontam remuneração como critério principal ao escolher uma empresa

Seguido por flexibilidade de trabalho remoto, com 56,6%

Fonte: Data Hackers e Bain & Company. State of Data Brasil 2025-2026.

O gargalo da inteligência artificial

90%

das empresas onde os respondentes trabalham já têm alguma iniciativa de IA generativa em curso.

34%

das que ainda não avançaram apontam o mesmo motivo: os dados não estão prontos para uso.

Outros 33,5% citam falta de expertise ou de recursos técnicos.

A barreira mais citada para adotar inteligência artificial é a qualidade dos dados. Preparar esse dado é exatamente o trabalho desta disciplina.

Fonte: Data Hackers e Bain & Company. State of Data Brasil 2025-2026.

PERFIL DE FORMAÇÃO

Quem são esses profissionais

54,1% não tinham experiência prévia na área de TI antes de migrar para dados

58% possuem algum tipo de pós-graduação

20,5% vêm de cursos de engenharia, atrás apenas de formações em TI

A área recebe pessoas de formações variadas e valoriza quem sabe construir. Uma base sólida de engenharia, somada a um projeto real no portfólio, é um ponto de partida competitivo.

Fonte: Data Hackers e Bain & Company. State of Data Brasil 2025-2026.

PROJETO DO SEMESTRE

O que você vai construir aqui

Um pipeline de dados completo, individual, sobre um tema escolhido por você. O projeto cresce em três camadas ao longo das aulas.

Ao final, cada aluno apresenta o pipeline e o dashboard construídos, com o código publicado no GitHub.

Bronze

Dado bruto

Ingestão de arquivos e APIs, exploração automatizada e avaliação de qualidade

Prata

Dado confiável

Limpeza, engenharia de atributos, enriquecimento com uma segunda fonte e carga em banco

Ouro

Dado pronto para uso

Modelagem, transformação em SQL com dbt, testes, documentação e dashboard

Na aula 2 veremos essa arquitetura em detalhe. Por ora, guarde a ideia: o dado melhora a cada camada.

Databricks. What is a medallion architecture? Padrão também adotado pelo Microsoft Fabric e pelo Azure.

DUAS UNIDADES

Como você será avaliado

Não há prova teórica. As duas notas do portal acadêmico vêm das entregas do seu próprio projeto.

Unidade 1

50%

Checkpoint 1
Camada bronze

50%

Checkpoint 2
Camada prata

Unidade 2

40%

Checkpoint 3
Camada ouro

60%

Projeto final
Entrega e apresentação

Os laboratórios de cada aula não têm nota própria. Eles constroem, semana a semana, exatamente aquilo que é avaliado no checkpoint da camada.

MÃOS À OBRA

Atividade de hoje

Escolha o tema e a fonte de dados do seu projeto

- 1 Escolha um tema que te interesse de verdade**
Você vai conviver com esses dados até o fim da disciplina
- 2 Defina a fonte primária**
Um conjunto de dados público, em arquivo ou API, que você consiga acessar hoje
- 3 Identifique uma fonte secundária candidata**
Algo que possa ser cruzado com a primeira mais adiante, sem compromisso ainda
- 4 Registre sua escolha no formulário da atividade no SIGAA**
Tema, links das fontes e uma pergunta que você gostaria de responder

REPOSITÓRIOS SUGERIDOS

Onde procurar dados

● Portal Brasileiro de Dados Abertos

dados.gov.br

Catálogo central do governo federal, com milhares de conjuntos

● IBGE

servicodados.ibge.gov.br/api/docs

API de dados agregados de censos e pesquisas

● Banco Central

dadosabertos.bcb.gov.br

Séries temporais econômicas, com API estável e bem documentada

● Agências reguladoras

[ANP](#), [ANAC](#), [ANEEL](#), [ANS](#)

Dados setoriais detalhados, em geral em arquivos grandes

● Portais municipais e estaduais

[Prefeituras e governos estaduais](#)

Mobilidade, orçamento, educação e saúde locais

● Kaggle e Hugging Face

kaggle.com, huggingface.co

Conjuntos internacionais, úteis quando o tema não é local