

UNIVERSIDADE FEDERAL DE ITAJUBÁ

Engenharia de Dados na Prática

Qualidade de dados na prática

Profa. Bárbara Pimenta Caetano

O que veremos hoje

- 1 O que é qualidade de dados, e o que ela não é
- 2 Ausentes, duplicados e valores extremos
- 3 Transformar a lista do README em código
- 4 Gravar a camada Prata em Parquet
- 5 Registrar as decisões, não só o resultado

A mesma tabela, dois destinos

Onde ficam as capitais no mapa?

A tabela de países serve mal. As coordenadas vêm como texto e faltam em parte dos registros.

Qualidade baixa.

Como o indicador varia por região?

A mesma tabela serve bem. O código do país e a região estão completos em todos os registros.

Qualidade alta.

Nenhuma linha mudou entre um caso e outro. O que mudou foi a pergunta.

Por isso não existe dado limpo em absoluto, e por isso cada um de vocês vai tomar decisões diferentes sobre a própria fonte.

Duas definições que brigam entre si

Adequação ao uso

O dado tem qualidade quando serve à tarefa de quem vai usá-lo.

A favor: descreve o que acontece de verdade.

Contra: não vira teste. Ninguém automatiza 'serve à tarefa'.

Conformidade com a especificação

O dado tem qualidade quando obedece ao que foi declarado: tipo, faixa, formato, regra.

A favor: testável, repetível, automatizável.

Contra: cega ao contexto. O dado passa em todos os testes e ainda assim não responde à pergunta.

O trabalho do engenheiro é converter uma na outra: transformar o que se sabe do uso em especificação escrita, e documentar o que não couber.

Quinze dimensões, quatro categorias

Intrínseca

exatidão, objetividade, credibilidade, reputação

o dado em si

Contextual

relevância, valor agregado, atualidade, completude, volume adequado

depende da tarefa

Representacional

interpretabilidade, facilidade de compreensão, consistência de representação, concisão

como o dado se apresenta

Acessibilidade

acesso, segurança de acesso

dá para chegar até ele

Duas das quatro categorias não falam do conteúdo do dado. Limpar dado não é sinônimo de ter qualidade.

WANG, R. Y.; STRONG, D. M. *Beyond accuracy: what data quality means to data consumers. Journal of Management Information Systems*, v. 12, n. 4, p. 5-33, 1996.

A norma separa pela origem do problema

Inerentes

5

exatidão, completude, consistência, credibilidade, atualidade

Dependentes do sistema

3

disponibilidade, portabilidade, recuperabilidade

Nos dois grupos

7

acessibilidade, conformidade, confidencialidade, eficiência, precisão, rastreabilidade, compreensibilidade

As inerentes você mede olhando para o dado. As dependentes do sistema vêm de onde

**A proveniência que vocês escrevem desde a ingestão é a característica rastreabilidade.
Não é capricho da disciplina: está na norma.**

ISO/IEC 25012:2008, modelo de qualidade de dados da família SQuaRE.

O que cabe a você

1

Medir e mostrar

Números, não adjetivos. 'Debut Year tem N ausentes em M linhas' diz algo. 'Muitos vazios' não diz nada.

2

Especificar o que der

Transformar o que você sabe do assunto em regra escrita, que o código consegue verificar sozinho.

3

Documentar o que não der

Quando não há regra possível, há registro. Quem for usar o dado decide com a informação na mão.

O engenheiro não decide sozinho o que é aceitável. Ele garante que a decisão seja possível.

Quatro perguntas para levar a campo

Completude

O dado está todo aqui?

Faltam linhas, faltam colunas, faltam valores.

Consistência

As partes combinam entre si?

Um total que não bate com a soma das parcelas.

Exatidão

O valor corresponde à realidade?

Uma população negativa, uma data no futuro.

Atualidade

O dado ainda vale?

Uma extração de dois anos atrás em um indicador anual.

Recorte operacional das dimensões inerentes da ISO/IEC 25012, que são as que se medem no próprio arquivo.

Onde estamos



Bronze

Pronta, imutável, com proveniência



Prata

Nasce hoje



Ouro

Modelagem e entrega

A Prata é a primeira camada em que você decide alguma coisa.

A lista do README vira código

O que você escreveu

- Nomes de região com espaço no fim
- Agregados regionais misturados aos países
- Coluna de capital vazia em vários registros



O que você escreve hoje

```
tirar_espacos()
```

```
separar_agregados()
```

```
tratar_ausentes()
```

Cada defeito que você anotou vira uma função com nome próprio. Se um defeito não virou função, ou ele não era defeito, ou ficou por resolver.

A Bronze não se toca



Se apagar a pasta da Prata inteira, um comando reconstrói tudo.

É isso que separa dado de resultado. O dado bruto é insubstituível, porque a fonte pode mudar amanhã. O resultado é descartável, porque o código o refaz.

Um vazio não quer dizer uma coisa só

Não foi coletado

O valor existe no mundo, mas ninguém registrou.

Não se aplica

A pergunta não faz sentido para aquele registro.

Foi registrado como vazio

O sistema de origem gravou vazio no lugar de zero, de 'não' ou de 'desconhecido'.

O tratamento correto depende de qual dos três é. E isso não está no dado: está na documentação da fonte.

O caso da capital vazia

Dois registros da mesma fonte, lado a lado:

```
{"id": "AFG", "name": "Afghanistan",  
  "capitalCity": "Kabul",  
  "region": {"value": "Middle East, ..."}}}
```

```
{"id": "AFE", "name": "Africa Eastern and Southern",  
  "capitalCity": "",  
  "region": {"value": "Aggregates"}}}
```

A capital não está faltando. Um agrupamento de países não tem capital. O vazio aqui é a resposta certa.

Resposta real da API do Banco Mundial, consultada durante o preparo desta aula.

Três saídas comuns para o ausente

1

Remover a linha

Quando o registro fica inútil sem aquele valor e a perda é pequena.

2

Preencher

Quando existe um valor defensável: outra coluna, outra fonte, uma regra de negócio.

3

Manter e sinalizar

Quando o vazio tem significado. Cria-se uma coluna que marca a ausência.

Existem outras. Buscar o valor em uma fonte complementar é a mais comum delas, e é exatamente o que faremos na aula de integração.

Duplicado é uma palavra para duas coisas

Linha idêntica

Todas as colunas iguais. Costuma vir de erro de carga: o mesmo arquivo processado duas vezes.

Fácil de achar.

Entidade repetida

A mesma coisa do mundo real aparece duas vezes, com valores diferentes em alguma coluna.

Só se acha se você souber a chave.

Antes de remover duplicado, responda: o que é uma linha na minha tabela? Um país? Um país por ano? Um artista? Um artista por álbum?

Escolher a chave é uma decisão de projeto

Banco Mundial

id

Código de três letras do país. Único por definição.

Artistas

primeira coluna

Nome do artista. Único enquanto não houver dois artistas homônimos.

Série temporal

entidade + data

Uma chave só não basta. A repetição no tempo é esperada.

Escreva a chave da sua fonte no README. Ela vai reaparecer na modelagem, quando virar chave primária de verdade.

Valor extremo não é sinônimo de erro

Um país com população cem vezes maior que a mediana

Não é erro. É a China. Remover essa linha destrói a análise.

Uma pessoa com 250 anos de idade

É erro. Nenhum ser humano tem 250 anos. Aqui a remoção se justifica.

A estatística aponta o candidato. Quem decide se é erro é você, com o que sabe do domínio.

Primeiro método: intervalo interquartil


Divide os dados ordenados em quatro partes e olha para a faixa do meio.

- Q1 é o valor que deixa 25% dos dados abaixo
- Q3 é o valor que deixa 75% dos dados abaixo
- IQR é a distância entre os dois: Q3 menos Q1

Fica marcado como extremo o que cair fora de:

$$\begin{aligned}\text{limite_inferior} &= Q1 - 1.5 * IQR \\ \text{limite_superior} &= Q3 + 1.5 * IQR\end{aligned}$$

Não depende do formato da distribuição e não se deixa influenciar pelo próprio valor extremo, porque quartis não são médias.



Segundo método: escore padronizado (z-score)


Mede quantos desvios padrão o valor está longe da média.

$$z = (\text{valor} - \text{média}) / \text{desvio_padrão}$$

A convenção mais usada marca como extremo o que tiver módulo de z acima de 3.

Duas limitações que você precisa conhecer

- Supõe uma distribuição aproximadamente simétrica. Em dados muito assimétricos, marca demais de um lado.
- A média e o desvio são calculados com o extremo dentro. Um valor absurdo eleva o desvio e acaba escondendo a si mesmo.



Qual usar

IQR

- Distribuição de qualquer formato
- Resistente ao próprio extremo
- Padrão do boxplot
- Marca mais pontos em dados assimétricos

Escore padronizado (z-score)

- Distribuição próxima da simétrica
- Sensível ao próprio extremo
- Comparável entre colunas diferentes
- Interpretação direta em desvios

Hoje vamos calcular os dois e comparar as listas. Onde eles discordam é onde vale olhar.

A regra que vamos seguir

Erro comprovado

Remove a linha e registra quantas foram.

Extremo legítimo

Mantém e marca com uma coluna de sinalização.

Dúvida

Mantém, marca, e escreve a dúvida no README.

Remover em silêncio é o pior dos três caminhos.

O CSV esquece o que você acabou de decidir

Você converte a coluna para número, salva em CSV e lê de novo:

```
df['longitude'] = pd.to_numeric(df['longitude'])
df.to_csv('prata.csv', index=False)

df2 = pd.read_csv('prata.csv')
# o pandas tenta adivinhar o tipo outra vez
```

O CSV guarda texto. Todo tipo de dado é reconstruído por adivinhação a cada leitura, e a adivinhação muda quando o conteúdo muda. Um código de município que começa com zero volta sem o zero.

Parquet: o formato da Prata

Guarda o tipo

A coluna volta como número, data ou texto, exatamente como saiu.

Guarda por coluna

Ler só duas colunas de uma tabela larga não custa ler o arquivo inteiro.

Comprime

Valores parecidos ficam vizinhos, então o arquivo encolhe bastante.

É formato aberto

Especificação pública, projeto da Apache Software Foundation, lido por qualquer ferramenta séria de dados.

Especificação em parquet.apache.org. O CSV continua sendo a escolha certa para entregar dado a quem vai abrir na planilha.

PASSO 1

Preparar o ambiente

Acrescente ao requirements.txt:

```
pandas  
kagglehub  
requests  
fg-data-profiling  
setuptools<82  
pyarrow
```

Com o ambiente virtual ativado, instale:

```
pip install -r requirements.txt
```

PASSO 2

Criar src/transformar_países.py

Um arquivo por fonte, igual à ingestão. Começamos pelos caminhos:

```
import json
from datetime import datetime
from pathlib import Path

import pandas as pd

BRONZE = Path("dados/bronze/banco_mundial")
PRATA = Path("dados/prata")
PADRAO = "países_*.csv"
```

PASSO 3

Carregar o arquivo mais recente

```
def carregar():
    arquivos = sorted(BRONZE.glob(PADRAO))
    if not arquivos:
        raise FileNotFoundError(f"nada em {BRONZE}")
    caminho = arquivos[-1]
    df = pd.read_csv(caminho)
    print("lido:", caminho.name, df.shape)
    return df, caminho

def main():
    df, origem = carregar()
```

A data no nome do arquivo, decidida na aula de ingestão, é o que faz o sorted devolver o mais

PASSO 4

Olhar antes de decidir

Acrescente dentro de `carregar()`, antes do `return`:

```
print(df.columns.tolist())  
print(df.isna().sum())
```

Duas perguntas para responder com essa saída

- Os nomes das colunas são utilizáveis, ou vêm com espaço, acento e maiúscula misturados?
- Quais colunas têm ausentes, e o número bate com o que o relatório da aula passada mostrou?

PASSO 5

Tirar os espaços sobrando

```
def tirar_espacos(df):  
    df.columns = df.columns.str.strip()  
    for coluna in df.select_dtypes(include="object"):  
        df[coluna] = df[coluna].str.strip()  
    return df
```

A primeira linha trata o nome da coluna, o defeito que você anotou na fonte de artistas. As outras tratam o conteúdo, como em 'Latin America & Caribbean ' com espaço no fim.

PASSO 6

Separar o que não é país

```
def separar_agregados(df):  
    e_pais = df["region.value"] != "Aggregates"  
    print("países      :", e_pais.sum())  
    print("agregados:", (~e_pais).sum())  
    return df[e_pais].copy()
```

Repare que isto não é limpeza de erro. Os agregados são dados corretos, apenas de outra granularidade. Misturar World com Brasil em uma soma é que seria o erro.

O `.copy()` evita o aviso do pandas sobre alterar uma fatia de outro DataFrame.

PASSO 7

Conferir a chave

```
def conferir_chave(df, chave="id") :  
    repetidas = df[chave].duplicated().sum()  
    print("chaves repetidas:", repetidas)  
    if repetidas:  
        print(df[df[chave].duplicated(keep=False)])  
    return df.drop_duplicates(subset=chave)
```

O if existe para você ver quem repetiu antes de apagar. Chave repetida costuma ser sintoma de outro problema, não a doença.

Na sua fonte, troque o valor padrão pela chave que você declarou no README.

PASSO 8

Converter os tipos

```
def converter_tipos(df):  
    for coluna in ["longitude", "latitude"]:  
        df[coluna] = pd.to_numeric(  
            df[coluna], errors="coerce")  
    return df
```

errors="coerce" transforma em ausente o que não for convertível, em vez de derrubar o script. É uma decisão, não um detalhe: você está escolhendo perder o valor inválido em silêncio. Por isso o passo seguinte conta quantos viraram ausentes.

PASSO 9

Marcar valores extremos por IQR

```
def limites_iqr(serie):  
    q1 = serie.quantile(0.25)  
    q3 = serie.quantile(0.75)  
    iqr = q3 - q1  
    return q1 - 1.5 * iqr, q3 + 1.5 * iqr  
  
def marcar_extremos(df, coluna):  
    baixo, alto = limites_iqr(df[coluna])  
    df[coluna + "_extremo"] = (  
        (df[coluna] < baixo) | (df[coluna] > alto))  
    print(coluna, df[coluna + "_extremo"].sum())  
    return df
```

PASSO 10

Comparar com o escore padronizado

```
def marcar_zscore(df, coluna, limite=3):  
    z = (df[coluna] - df[coluna].mean()) / df[coluna].std()  
    df[coluna + "_z"] = z.abs() > limite  
    print(coluna, "z acima de", limite, ":",  
          df[coluna + "_z"].sum())  
    return df
```

Rode os dois na mesma coluna e compare os totais. Onde um marca e o outro não, olhe a linha e decida você. Essa divergência é o assunto da discussão de hoje.

PASSO 11

Remover só o erro comprovado

```
def remover_erros(df, coluna, minimo, maximo):  
    valido = df[coluna].between(minimo, maximo)  
    print("removidas:", (~valido).sum())  
    return df[valido].copy()
```

A faixa vem do domínio, não da estatística

- Longitude fora de -180 a 180 é erro, e isso é geografia, não análise.
- Ano de estreia anterior à invenção da gravação sonora é erro.
- Se você não consegue escrever a faixa, então não é erro: é extremo. Só marque.

PASSO 12

Gravar a Prata em Parquet

```
def salvar(df):  
    PRATA.mkdir(parents=True, exist_ok=True)  
    destino = PRATA / "países.parquet"  
    df.to_parquet(destino, index=False)  
    print("salvo em:", destino, df.shape)  
    return destino
```

Sem data no nome, ao contrário da Bronze. A Prata é reconstruível: cada execução substitui a anterior, e a versão que vale é sempre a última.

PASSO 13

Registrar as decisões, não só o resultado

```
def registrar(origem, destino, antes, depois, decisoes):  
    info = {  
        "origem": origem.name,  
        "arquivo_prata": destino.name,  
        "linhas_antes": antes,  
        "linhas_depois": depois,  
        "decisoes": decisoes,  
        "transformado_em": datetime.now().isoformat(  
            timespec="seconds"),  
    }  
    caminho = PRATA / "proveniencia.jsonl"  
    with caminho.open("a", encoding="utf-8") as f:  
        f.write(json.dumps(info, ensure_ascii=False) + "\n")
```

PASSO 14

Montar a main

```
def main():  
    df, origem = carregar()  
    antes = len(df)  
    df = tirar_espacos(df)  
    df = separar_agregados(df)  
    df = conferir_chave(df)  
    df = converter_tipos(df)  
    destino = salvar(df)  
    registrar(origem, destino, antes, len(df), [  
        "espacos removidos",  
        "agregados separados",  
        "longitude e latitude convertidas",  
    ])
```

PASSO 15

Rodar e conferir a saída

```
python src/transformar_paises.py
```

O que a saída precisa mostrar:

Quantas linhas entraram e quantas saíram

Se a diferença surpreender, alguma função removeu mais do que devia.

Quanto agregados foram separados

Confira contra o que o relatório da aula passada mostrou.

Onde o arquivo foi gravado

Abra a pasta e veja o Parquet lá, com tamanho menor que o CSV de origem.

PASSO 16

Escrever as decisões no README

```
## Decisões de tratamento
```

Banco Mundial

- Espacos removidos de nomes de coluna e de texto.
- Agregados regionais separados: N linhas retiradas.
Motivo: granularidade diferente da dos paises.
- Longitude e latitude convertidas para numero.
Vazios viraram ausentes: N ocorrencias.
- Capital vazia mantida. Nao se aplica a agregados.

Uma linha por decisão, com o número que você viu e o motivo. Quem ler o repositório daqui a seis meses precisa entender por que o total mudou.

O que vai para o GitHub

sobe

`src/transformar_paises.py`

O código é o que reconstrói tudo.

sobe

`dados/prata/proveniencia.jsonl`

Registro histórico, não se reconstrói igual.

fica de fora

`dados/prata/paises.parquet`

Um comando refaz o arquivo.

Acrescente uma exceção ao `.gitignore`:

`!dados/prata/proveniencia.jsonl`

Antes de fechar o computador

- O script roda do início ao fim sem editar nada à mão
- A Bronze continua exatamente como estava
- O Parquet está na Prata e a proveniência tem a linha de hoje
- O README tem a seção de decisões, com números
- Commit e push feitos

Na próxima aula: padronização de texto e datas, e criação de atributos derivados.

Para aprofundar

Leitura principal

MOSES, B.; GAVISH, L.; VORWERCK, M. Fundamentos da qualidade de dados. Alta Books, 2024. Capítulos iniciais.

Documentação

Guia de dados ausentes do pandas, e a especificação do formato Parquet em parquet.apache.org.

Para quem quiser mais

REIS, J.; HOUSLEY, M. Fundamentos de engenharia de dados. Novatec, 2023. Capítulo de transformação.